Introduzione all'Intelligenza Artificiale

Incontro 2 — Parte 2: Bias e responsabilità algoritmica

Giovanni Della Lunga
giovanni.dellalunga@unibo.it

Prefettura di Milano

Ottobre-Novembre 2026

Indice della Parte 2

1. Il cambio di prospettiva
2. Come nasce il bias
3. Il caso COMPAS
4. Il caso PredPol e la polizia predittiva
5. E in Europa? E in Italia?
6. Opacità, *black box* e spiegabilità
7. Supervisione umana e automation bias
8. Esercizio pratico
9. Chiusura
10. Appendice A: Approfondimento del caso COMPAS
11. Appendice B: COMPAS e PredPol alla luce dell'AI Act

Il cambio di prospettiva

Due modi molto diversi di incontrare l'IA

Nella prima parte: l'IA come *strumento*

- **Voi** decidete di usarla
- **Voi** formulate la richiesta
- **Voi** valutate l'output
- **Voi** potete scartarlo
- Se sbaglia, ve ne potete accorgere — *se verificate*

Il controllo è vostro.

Adesso: l'IA come *decisore*

- **Il sistema** classifica un cittadino
- **Il sistema** assegna un punteggio
- **Il sistema** raccomanda un esito
- Voi lo ricevete già fatto
- Se sbaglia, forse **nessuno se ne accorge**

Il controllo è... di chi?

La seconda situazione è quella che riguarderà sempre di più la pubblica amministrazione.

Perché questa parte è la più importante

Un ragionamento semplice

- Un errore dell'assistente che scrive male un avviso: è sotto i vostri occhi, e **chi verifica lo corregge**.
- Un errore di un sistema che classifica come "ad alto rischio" un cittadino innocente: **può non essere mai scoperto**.

L'asimmetria che dovrebbe inquietarci

Chi subisce una decisione algoritmica sfavorevole:

- Spesso **non sa** che c'è stato un algoritmo
- Se lo sa, **non sa come funziona**
- Se lo sapesse, **non potrebbe verificarlo**
- E chi ha firmato il provvedimento, **spesso non lo sa neanche lui**

Come nasce il bias

Il bias: una definizione operativa

Che cos'è un bias algoritmico

Un **errore sistematico** — non casuale — per cui un sistema produce risultati che svantaggiano in modo consistente un determinato gruppo di persone.

Il punto cruciale, spesso frainteso

Il bias **non è un difetto di programmazione**.

Nessuno ha scritto una riga di codice che dice "*penalizza il gruppo X*". Il sistema funziona **esattamente come progettato**: ha imparato dai dati che gli sono stati dati, seguendo le scelte di chi lo ha costruito — che cosa prevedere, quali variabili usare, come etichettare gli esempi.

Il problema è nei dati e nelle scelte di progetto. Nessuno dei due è neutro.

Un algoritmo addestrato sulla storia riproduce la storia — comprese le sue ingiustizie.

Le quattro strade per cui il bias entra in un sistema

1. Bias nei dati storici

I dati registrano il *passato*. Se il passato era discriminatorio, i dati lo sono.
Es.: i dati sugli arresti riflettono anche dove la polizia ha pattugliato, non solo dove sono avvenuti i reati.

2. Bias di campionamento

Alcuni gruppi sono **sotto-rappresentati** nei dati.
Es.: i sistemi di riconoscimento facciale addestrati prevalentemente su volti maschili e chiari.

3. Bias nella definizione e nell'etichettatura

Qualcuno ha deciso che cosa prevedere e come classificare gli esempi.
Es.: che cosa conta come "comportamento sospetto"? E come "rischio di frode"? Lo decide un essere umano.

4. Bias nella scelta delle variabili

Le *proxy*: variabili apparentemente neutre che rivelano caratteristiche protette.
Es.: il CAP di residenza può essere una proxy forte del reddito o dell'origine etnica.

Le variabili *proxy*: il bias che si nasconde

Il trucco che non funziona

"*Basta togliere l'etnia dalle variabili, e il sistema non può discriminare.*" **Falso.** Il sistema può ricostruire l'informazione da altre variabili.

Variabili che possono fare da proxy

- **CAP / quartiere** → reddito, origine etnica
- **Nome e cognome** → origine nazionale
- **Scuola frequentata** → classe sociale
- **Tipo di contratto** → età, genere
- **Storia dei contatti con la PA** → fragilità sociale

Il paradosso

Togliere la variabile sensibile non elimina la discriminazione. E c'è di peggio: **senza quel dato non si può più nemmeno misurarla**.

Per questo l'AI Act (art. 10, par. 5) consente, in via eccezionale e con garanzie, di trattare categorie particolari di dati personali proprio per individuare e correggere i bias.

Le variabili *proxy*: il bias che si nasconde

5. Nella misura in cui ciò sia strettamente necessario al fine di garantireil rilevamento e la correzione delle distorsioni in relazione ai sistemi di IA ad alto rischio in conformità del paragrafo 2, lettere f) e g), del presente articolo, i fornitori di tali sistemi possono eccezionalmente trattare categorie particolari di dati personali, fatte salve le tutele adeguate per i diritti e le libertà fondamentali delle persone fisiche. Oltre alle disposizioni di cui ai regolamenti (UE) 2016/679 e (UE) 2018/1725 e alla direttiva (UE) 2016/680 devono essere soddisfatte, affinché tale trattamento avvenga, tutte le condizioni seguenti:

a) il rilevamento e la correzione delle distorsioni non possono essere realizzati efficacemente mediante il trattamento di altri dati, compresi i dati sintetici o anonimizzati;

b) le categorie particolari di dati personali sono soggette a limitazioni tecniche relative al riutilizzo dei dati personali, nonché a misure più avanzate di sicurezza e di tutela della vita privata, compresa la pseudonimizzazione;

c) le categorie particolari di dati personali sono soggette a misure tese a garantire che i dati personali trattati siano resi sicuri e protetti nonché soggetti a garanzie adeguate, ivi compresi controlli e documentazione rigorosi dell'accesso, al fine di evitare abusi e garantire che solo le persone autorizzate e sottostanti a opportuni obblighi di riservatezza abbiano accesso a tali dati personali;

d) le categorie particolari di dati personali non devono essere trasmesse, trasferite o altrimenti consultate da terzi;

e) le categorie particolari di dati personali vengono cancellate dopo che la distorsione è stata corretta oppure i dati personali hanno raggiunto la fine del loro periodo di conservazione, a seconda di quale delle due condizioni si verifica per prima;

Il caso COMPAS

COMPAS: l'algoritmo che prevede la recidiva

Che cos'è

COMPAS (*Correctional Offender Management Profiling for Alternative Sanctions*) è un sistema usato in numerosi tribunali statunitensi per stimare il rischio che un imputato commetta nuovi reati.

Come funziona:

- Un questionario di oltre 100 domande sull'imputato
- Produce un punteggio di rischio da **1 a 10**
- Il punteggio è usato dai giudici per decisioni su **cauzione**, **libertà vigilata**, talvolta **entità della pena**
- È un sistema **proprietario**: l'algoritmo è segreto

Usato su larga scala. Nessuno, fuori dall'azienda, sa esattamente come funziona.

COMPAS: l'inchiesta

2016: ProPublica analizza i dati

Un gruppo di giornalisti investigativi esamina i punteggi COMPAS di oltre settemila persone arrestate in una contea della Florida, e li confronta con ciò che è *effettivamente* accaduto nei due anni successivi: chi è stato **arrestato di nuovo**.

Che cosa emerge

- Tra chi **non** è stato arrestato di nuovo, era stato classificato **ad alto rischio** il 45% degli **afroamericani** contro il 23% dei bianchi
- Tra chi è stato arrestato di nuovo, era stato classificato **a basso rischio** il 48% dei **bianchi** contro il 28% degli afroamericani
- **Gli errori non erano distribuiti a caso. Erano distribuiti secondo l'etnia.**

Attenzione: si misura il nuovo arresto, non il nuovo reato. È la prima delle quattro strade del bias.

COMPAS: la difesa dell'azienda

La replica di Northpointe (oggi Equivant), l'azienda produttrice

In sintesi: *il nostro sistema è equo, perché a parità di punteggio la probabilità di recidiva è la stessa per tutti i gruppi etnici.*

E qui viene il punto più interessante di tutta la storia

Avevano ragione entrambi.

ProPublica misurava una cosa (*gli errori sono distribuiti in modo diseguale*).
Northpointe ne misurava un'altra (*a parità di punteggio, il rischio è lo stesso*).

Entrambe le affermazioni erano **statisticamente vere**.

Com'è possibile?

Il teorema dell'impossibilità

Un risultato matematico dimostrato (Kleinberg et al., 2016; Chouldechova, 2017)

Tre criteri di equità, tutti ragionevoli:

1. a parità di punteggio, stesso rischio *(la tesi di Northpointe)*
2. stessa quota di **falsi allarmi** in ogni gruppo
3. stessa quota di **casi sfuggiti** in ogni gruppo *(la tesi di ProPublica, punti 2 e 3)*

Se l'evento da prevedere ha **frequenze diverse** nei due gruppi (nel caso COMPAS: tassi di nuovo arresto diversi) e la previsione non è perfetta, **i tre criteri non possono valere insieme**. Bisogna **scegliere**.

La conseguenza, che va compresa a fondo

Non esiste un algoritmo "equo" in assoluto. Ogni sistema incorpora una **scelta di valore** su quale forma di equità privilegiare.

Questa scelta è **normativa**, non solo tecnica. E spesso viene fatta in fase di progettazione, senza che chi usa il sistema ne sia informato.

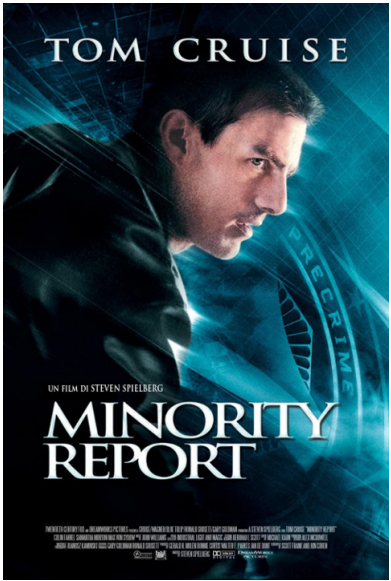
COMPAS: che cosa ci insegna

1. **Il bias non richiede cattiva fede.** Nessuno voleva discriminare.
2. **L'opacità impedisce il controllo.** L'algoritmo era segreto: nemmeno i giudici sapevano come funzionava.
3. **L'equità non è solo un problema tecnico.** È anche una scelta di valore, spesso presentata come specifica tecnica.
4. **L'apparenza di oggettività è pericolosa.** Un numero da 1 a 10 sembra un fatto. Non lo è.
5. **Senza audit indipendenti, nessuno se ne accorge.** Ci sono voluti dei giornalisti.

E un dettaglio che pochi ricordano:
COMPAS non si è rivelato più accurato di persone senza competenze specifiche, né di un modello semplice con due sole variabili (Dressel e Farid, 2018).

Il caso PredPol e la polizia predittiva

La polizia predittiva



L'idea

Usare i dati storici sui reati per **prevedere dove** avverranno i prossimi, e concentrare lì le pattuglie.

PredPol è stato uno dei sistemi più diffusi negli Stati Uniti.

La polizia predittiva

Perché sembra un'ottima idea

- Ottimizza risorse scarse
- Sembra oggettivo: si basa sui dati, non sull'intuito
- Promette di prevenire, non solo di reprimere
- È politicamente vendibile: "*polizia scientifica*"

Ed è esattamente per questo che è pericoloso.

PredPol: il vizio d'origine

Su quali dati si basa il sistema?

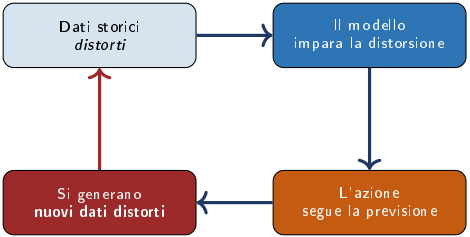
Sui **reati registrati dalla polizia**: tipo, luogo, ora. Nessun dato personale: sembra neutro.
Ma un reato entra nei dati solo se qualcuno lo **osserva** o lo **denuncia** — e dove si pattuglia di più, si osserva di più.

Il meccanismo, passo per passo

1. Storicamente la polizia ha pattugliato di più certi quartieri
2. In quei quartieri sono stati **registrati** più reati — non necessariamente **commessi** più reati
3. Il sistema impara: "*qui succedono più cose*"
4. Il sistema manda più pattuglie in quei quartieri
5. Più pattuglie → **più reati osservati e registrati**
6. I nuovi dati **confermano** la previsione
7. Torna al punto 3

Lum e Isaac (2016) lo hanno mostrato simulando l'algoritmo sui dati di Oakland sui reati di droga.

Il *feedback loop*: lo schema generale



La spirale
si stringe
a ogni giro

Il paradosso

Il sistema **sembra funzionare sempre meglio**: le sue previsioni si avverano.
Ma si avverano **anche perché il sistema ha contribuito a causarle**, non solo perché fossero corrette.

Lo schema vale ovunque l'azione guidata dal sistema produca i dati con cui il sistema viene aggiornato.

PredPol: le conseguenze

Che cosa accade nella realtà

- Le aree più pattugliate — tipicamente comunità povere e di minoranza — **generano più dati**, che alimentano previsioni ulteriormente sbilanciate
- Interi quartieri, già stigmatizzati, rischiano di essere **sorvegliati e criminalizzati ingiustamente**

L'assenza di controllo

- Molti algoritmi sono **proprietari** (*black box*): né la comunità né le autorità possono verificarne il funzionamento
- **Senza audit indipendenti**, un programma può continuare a operare per anni malgrado effetti negativi tangibili — come è accaduto con PredPol, attivo a lungo pur in assenza di prove convincenti della sua efficacia

E in Europa? E in Italia?

Paesi Bassi: due casi, una lezione

SyRI

Incrociava dati di fonti diverse per segnalare possibili **frodi nel welfare**.

- Applicato soprattutto nei **quartieri più poveri**
- I cittadini **non sapevano** di essere valutati
- **2020**: il tribunale dell'Aja lo dichiara contrario all'art. 8 CEDU (*rispetto della vita privata*)

Lo scandalo degli assegni familiari

L'amministrazione fiscale usava un modello di rischio che tra gli indicatori considerava la **nazionalità**.

- Migliaia di famiglie trattate come frodatrici, con richieste di **restituzione integrale**
- **2021**: dimissioni del governo; il Garante olandese sanziona l'amministrazione (2,75 milioni di euro) per trattamento **discriminatorio** della nazionalità

Il governo non è caduto per un algoritmo.
Ma un algoritmo ha reso sistematico — e invisibile — l'errore di un'amministrazione.

In Italia: il Consiglio di Stato e la mobilità dei docenti

Il caso

Nel 2016 la mobilità dei docenti della scuola viene gestita da un algoritmo. Molti docenti si ritrovano assegnati a sedi lontane, senza poter capire perché.

Non era nemmeno IA: era un software tradizionale. I principi valgono a maggior ragione per l'IA.

Che cosa dice il giudice amministrativo (Cons. Stato, sez. VI, n. 2270/2019 e n. 8472/2019)

- **Conoscibilità**: chi è destinatario della decisione ha diritto di sapere che esiste un algoritmo e di comprenderne la logica
- **Non esclusività**: deve esserci un contributo umano capace di controllare, validare o smentire la decisione
- **Non discriminazione**: l'algoritmo non deve produrre effetti discriminatori

Opacità, supervisione, bias: i tre temi di questa lezione, già scritti nella giurisprudenza italiana.

Perché tutto questo riguarda voi

L'AI Act considera ad alto rischio usi specifici dell'IA in ambiti come:

- Attività di contrasto (*law enforcement*)
- Migrazione, asilo e controllo delle frontiere
- Amministrazione della giustizia
- Accesso a servizi pubblici essenziali

E alcuni usi sono vietati (art. 5)

Valutare il rischio che una persona commetta un reato basandosi **unicamente** sulla profilazione o sui tratti della personalità.
Un sistema come COMPAS, in Europa, andrebbe vagliato prima di tutto rispetto a questo divieto. La previsione *per luoghi*, come PredPol, non rientra invece nel divieto.

Questi non sono ambiti astratti.

Opacità, *black box* e spiegabilità

Il problema dell'opacità

Le applicazioni di IA come *black box*

- Possono produrre risultati accurati senza che si possa capire **come** ci arrivano
- Nei modelli più complessi, nemmeno chi li ha costruiti sa spiegare come si forma la singola decisione
- Il problema pesa di più dove le decisioni toccano le persone: medicina, diritto, amministrazione

Tre tipi di opacità, spesso confusi (Burrell, 2016)

- **Opacità commerciale**: l'algoritmo è segreto perché è proprietà industriale. *È un problema di natura legale.*
- **Opacità intrinseca**: anche avendo il codice, una rete con miliardi di parametri **non è comprensibile**. *È un problema tecnico.*
- **Opacità di competenza**: chi usa il sistema non ha gli strumenti per capirlo. *È un problema di formazione.*

Il primo si affronta con la legge. Il secondo, in parte, con la scelta del modello. Il terzo è quello che stiamo affrontando adesso.

L'*explainability* (spiegabilità)

Definizione

La capacità di **comprendere e spiegare** il processo decisionale di un modello.

Perché è essenziale:

- Per evitare errori, discriminazioni, danni sistemici
- Perché **anche un modello preciso può essere rischioso** se non è comprensibile a chi lo usa
- Perché senza spiegazione non c'è **contestabilità**
- Perché senza contestabilità non c'è **tutela**

Per la PA il nesso è diretto:
senza spiegazione non c'è motivazione, e senza motivazione il provvedimento è vulnerabile.

Come si ottiene la spiegabilità

Modelli spiegabili per costruzione

Modelli in cui la relazione tra dati e risultato è **chiara e leggibile**: la regressione, gli alberi decisionali non troppo profondi.

Potete letteralmente seguire il ragionamento.

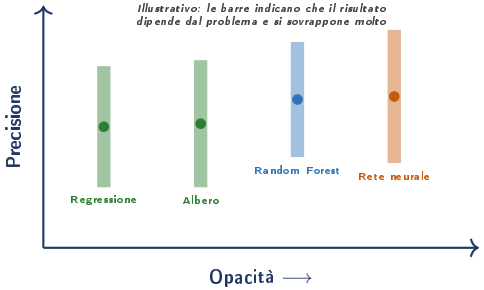
Spiegazioni costruite *dopo*

Per i modelli opachi si usano strumenti che, a posteriori, stimano quanto ciascuna variabile ha pesato su una decisione.

Danno un'idea utile — ma sono **approssimazioni**, non la verità del modello.

Quando un modello spiegabile funziona altrettanto bene,
non c'è ragione di preferirne uno opaco.

Il compromesso: precisione contro spiegabilità?



Una tendenza, non una legge

Su dati strutturati — come quelli tipici della PA — i modelli semplici spesso reggono il confronto con quelli complessi.

Il contesto decide

- In **medicina** o **diritto** → meglio modelli spiegabili, anche a costo di qualche punto di precisione
- In **meteorologia** o **logistica** → può prevalere la precisione
- **Nella PA** → la spiegabilità non è un lusso: è un requisito di legittimità

Non esiste una spiegazione "taglia unica"

Utenti diversi hanno bisogni esplicativi diversi

- Un **ingegnere** vuole sapere quali parametri hanno pesato
- Un **dirigente** vuole sapere se il sistema è affidabile nel complesso
- Un **funzionario** vuole sapere se può fidarsi di *questa* specifica raccomandazione
- Un **cittadino** vuole sapere **perché proprio a lui** è stato negato qualcosa
- Un **giudice** vuole sapere se la decisione è difendibile

La spiegabilità va adattata a chi deve capire.
Una spiegazione che nessuno comprende non è una spiegazione.

Supervisione umana e automation bias

Il principio di supervisione umana

Che cosa dice la normativa

Per i sistemi ad alto rischio, l'AI Act (art. 14) richiede che siano progettati per consentire una **sorveglianza umana** efficace: chi li usa deve poter **non tenere conto** dell'output, **annullarlo o ribaltarlo** e, se necessario, **interrompere** il sistema.

Che cosa NON È supervisione reale

- × Apporre una firma su un provvedimento già redatto dal sistema
- × Cliccare "conferma" su una schermata
- × Avere *teoricamente* la possibilità di dissentire, ma senza tempo né informazioni per farlo

In questi casi chi firma resta il responsabile, senza aver avuto strumenti reali di controllo.

La firma finale, da sola, non basta.

Le condizioni di una supervisione reale

L'AI Act (art. 26) chiede all'ente che usa un sistema ad alto rischio di affidare la sorveglianza a persone con la **competenza**, la **formazione** e l'**autorità** necessarie, e con il **sostegno** necessario. In pratica, tre condizioni:

1. **Competenza**
   Chi supervisiona deve *capire* che cosa il sistema sta facendo. Non deve saperlo programmare, ma deve conoscerne limiti, logica generale e modalità tipiche di errore.
2. **Informazione**
   Chi supervisiona deve avere accesso a *tutti* gli elementi su cui il sistema ha basato la raccomandazione. Un punteggio senza motivazione non è supervisionabile.
3. **Autorità e tempo**
   Chi supervisiona deve poter *davvero* dissentire, senza penalizzazioni, e deve avere il tempo materiale per farlo.

Se manca anche una sola di queste tre

Non c'è supervisione umana.
C'è solo un umano che si prende la responsabilità della macchina.

L'*automation bias*

Definizione

La tendenza sistematica a **fidarsi eccessivamente** di un sistema automatizzato, accettandone i suggerimenti anche quando elementi contrari sarebbero disponibili.

Si manifesta in due forme:

- **Errori di commissione**: seguo il sistema anche quando ho informazioni che lo contraddicono
- **Errori di omissione**: non noto un problema perché il sistema non me lo ha segnalato

Il paradosso della delega

Più il sistema è sofisticato e affidabile,
più diventa difficile esercitare su di esso un controllo critico efficace.

Se sbaglia una volta su mille, alla millesima pratica... chi ha ancora la lucidità di controllare?

Perché ci fidiamo troppo: i meccanismi

1. L'aura di oggettività del numero

Un punteggio "7,4 su 10" sembra un *fatto*. Un parere umano sembra un'*opinione*. Ma anche il 7,4 è il frutto di scelte umane, cristallizzate in cifra.

2. La riduzione dello sforzo cognitivo

Pensare costa fatica. Accettare no. Il cervello sceglie la via meno cara.

3. La diffusione della responsabilità

"*L'ha detto il sistema*" è psicologicamente rassicurante — anche se giuridicamente non vi esonera.

4. L'asimmetria degli incentivi

Seguire il sistema e sbagliare: *ho seguito la procedura*.
Discostarsi e sbagliare: *me ne assumo tutta la colpa*.
Il sistema di incentivi rischia di premiare la passività.

Il bias di conferma: quando il sistema ci dà ragione

Definizione

La tendenza a cercare, interpretare e ricordare le informazioni in modo da **confermare ciò che già pensiamo**.

Che cosa ha osservato la ricerca sulla PA (Alon-Barkat e Busuioc, 2023)

In esperimenti condotti nei Paesi Bassi i partecipanti **non** si sono fidati di un algoritmo più che di un esperto umano.

Ma in uno degli studi tendevano ad accettare il consiglio — da chiunque venisse — **soprattutto quando confermava uno stereotipo**.

La lezione

Il rischio non è solo fidarsi troppo della macchina.
È fidarsene **quando dice ciò che ci aspettavamo di sentire**.

Come difendersi dall'*automation bias*

Strategie individuali

- **Formulare la propria ipotesi prima** di guardare la raccomandazione del sistema
- Chiedersi sempre: *"su quali dati si sta basando?"*
- Prestare attenzione particolare ai casi in cui il sistema **conferma** ciò che già pensavate (lì il controllo si abbassa di più)
- Trattare il divergere dal sistema come **normale**, non come eccezionale

Strategie organizzative

- **Non chiedere di motivare solo il dissenso**: chiedere di motivare *anche l'adesione*
- Prevedere **controlli a campione** sui casi in cui si è seguito il sistema
- **Monitorare** il tasso di adesione: se è vicino al 100%, è un **segnale d'allarme** — la supervisione potrebbe essere solo formale

Esercizio pratico

Esercizio — Lo scenario

Il contesto (fittizio)

Il vostro ente ha adottato in via sperimentale un sistema di supporto decisionale che analizza le istanze in arrivo e assegna a ciascuna un **punteggio di priorità** e un **indicatore di rischio** (verde / giallo / rosso), per orientare l'ordine di lavorazione e il livello di approfondimento istruttorio.

Il caso

Vi arriva una pratica. La documentazione presentata dal richiedente vi sembra, a prima vista, **del tutto regolare**.

Prima di andare avanti: che idea vi siete fatti della pratica?

Esercizio — Lo scenario

Il contesto (fittizio)

Il vostro ente ha adottato in via sperimentale un sistema di supporto decisionale che analizza le istanze in arrivo e assegna a ciascuna un **punteggio di priorità** e un **indicatore di rischio** (verde / giallo / rosso), per orientare l'ordine di lavorazione e il livello di approfondimento istruttorio.

Il caso

Vi arriva una pratica. La documentazione presentata dal richiedente vi sembra, a prima vista, **del tutto regolare**.

Prima di andare avanti: che idea vi siete fatti della pratica?

- Il sistema la segnala: **punteggio di rischio 8,2 / 10** — indicatore **ROSSO**
- Raccomandazione: *"approfondimento istruttorio rafforzato"*
- Nessuna motivazione fornita

Esercizio — Lavoro in piccoli gruppi (20 minuti)

Discutete e mettete per iscritto

1. **Che cosa fate?** Seguite la raccomandazione, la ignorate, o fate altro?
2. **Quali informazioni vi mancano** per decidere in modo fondato?
3. **Che cosa chiedereste al sistema**, se poteste interrogarlo?
4. **A chi vi rivolgereste** dentro l'ente?
5. **Se decidete di discostarvi**, come documentate la scelta nel fascicolo?
6. **Se decidete di seguirlo**, come documentate la scelta?

Nota: la domanda 6 è quella che quasi nessuno si pone. Ed è la più insidiosa.

Esercizio — Le domande che dovrebbero emergere

Sul sistema

- Su quali **variabili** si basa il punteggio?
- Su quali **dati storici** è stato addestrato?
- Qual è il suo **tasso di errore**? E come si distribuisce?
- Chi lo ha **validato**? È stato sottoposto ad audit?
- Il punteggio è stato **tarato** su una popolazione simile alla nostra?

Sul procedimento

- Il richiedente **sa** di essere stato profilato?
- Il punteggio finirà nella **motivazione** del provvedimento finale?
- In caso di ricorso, **che cosa esibiremo**?
- Se il sistema sbaglia sistematicamente su un certo gruppo, **chi se ne accorgerebbe**?

Esercizio — Il debriefing

Confrontiamo le scelte dei gruppi

- Quanti hanno **seguito** la raccomandazione? Quanti se ne sono **discostati**?
- Quanti hanno pensato di **chiedere informazioni** prima di decidere?
- Quanti si sono chiesti se il richiedente **sapesse** di essere valutato da un algoritmo?

L'osservazione scomoda

Chi ha seguito il sistema non lo ha fatto per pigrizia: discostarsi costa, e il sistema di incentivi non premia chi lo fa.

Chi non lo ha seguito si chieda: lo farei anche alla duecentesima pratica della giornata, con l'ufficio in arretrato?

E attenzione: *"approfondimento rafforzato"* **non è una scelta neutra**. Più controlli significano più tempi, più oneri, più sospetto: è il meccanismo degli assegni familiari olandesi.

Ecco perché il problema non è mai solo individuale. È **organizzativo**.

Chiusura

I punti fermi di questa seconda parte

1. Il **bias** non nasce dalla cattiva fede: nasce dai **dati**, che riflettono la nostra storia, e dalle **scelte** di chi costruisce il sistema.
2. Rimuovere la variabile sensibile **non elimina** la discriminazione: la nasconde, e rende più difficile misurarla.
3. I **feedback loop** rendono il bias autoconfermante: il sistema sembra sempre più accurato mentre diventa sempre più ingiusto.
4. Non esiste un algoritmo **equo in assoluto**: l'equità è una scelta di valore, non un parametro tecnico.
5. L'**opacità** impedisce il controllo, e senza controllo non c'è tutela.
6. La **supervisione umana** richiede competenza, informazione e autorità, con il tempo per esercitarla. Senza, è solo formale.
7. L'**automation bias** non è solo una questione individuale: dipende anche dagli incentivi dell'organizzazione.
8. In Italia il **Consiglio di Stato** lo ha già detto: conoscibilità, non esclusività, non discriminazione.

Il messaggio da portare via

Un sistema algoritmico non solleva mai l'amministrazione dalla responsabilità.

La sposta soltanto — rendendola più difficile da vedere e da esercitare.

Ed è esattamente per questo che serve un funzionario che sappia fare alla scatola le domande giuste.

Cosa faremo nel terzo incontro

Incontro 3 — Governare l'IA

Prima parte: il quadro normativo

- L'AI Act: struttura e approccio basato sul rischio
- I sistemi ad alto rischio e gli obblighi per chi li usa
- Calendario di attuazione e sanzioni
- GDPR e trattamento dei dati personali

Seconda parte: etica e pratica

- I principi etici dell'IA nella PA
- Come valutare un sistema prima di adottarlo
- Come documentare l'uso dell'IA in un procedimento
- **Tre esercitazioni pratiche** con l'assistente IA in uso nel vostro ente
- Prospettive e chiusura del corso

Grazie

Domande e discussione

Giovanni Della Lunga

giovanni.dellalunga@unibo.it
Università di Bologna

Materiale del corso:
https://github.com/polyhedron-gdl

Appendice A: Approfondimento del caso COMPAS

Il problema: due affermazioni vere che sembrano incompatibili

ProPublica

Tra le persone che **non** sono state arrestate di nuovo, gli afroamericani erano stati segnalati "ad alto rischio" molto più spesso dei bianchi.

Il sistema è ingiusto.

Northpointe

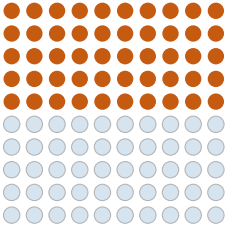
Tra le persone segnalate "ad alto rischio", la quota di chi è stato arrestato di nuovo era la stessa per afroamericani e bianchi.

Il sistema è equo.

Avevano ragione entrambi. Per capire come sia possibile non serve la statistica: bastano 200 persone e un po' di pazienza.

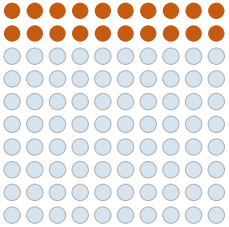
Un esempio inventato: due gruppi di 100 persone

Gruppo A



50 su 100 saranno arrestati di nuovo

Gruppo B



20 su 100 saranno arrestati di nuovo

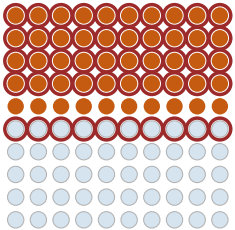
sarà riarrestato non sarà riarrestato

L'unica differenza tra i due gruppi

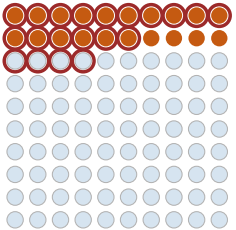
Nel gruppo A l'evento da prevedere è **più frequente** (50% contro 20%). È il punto su cui tutto ruota. *I numeri sono inventati, scelti perché i conti tornino facili.*

Il sistema fa le sue segnalazioni

Gruppo A: 50 segnalati



Gruppo B: 20 segnalati



sarà riarrestato non sarà riarrestato segnalato “alto rischio”

Il sistema non è perfetto: in entrambi i gruppi segnala qualcuno che non sarà arrestato di nuovo, e lascia sfuggire qualcuno che lo sarà. Ora facciamogli **tre domande**.

Prima domanda: quanto vale l'etichetta "alto rischio"?

La domanda di Northpointe — e del giudice

Se il sistema dice "alto rischio", quante volte ha ragione?

	Segnalati	Di cui riarrestati	L'etichetta ha ragione
Gruppo A	50	40	**80%**
Gruppo B	20	16	**80%**

Verdetto

L'etichetta **significa la stessa cosa** in entrambi i gruppi. Il giudice può leggerla senza chiedersi chi ha davanti.

Da questo punto di vista, il sistema è equo.

Seconda domanda: chi viene colpito per errore?

La domanda di ProPublica — e dell'imputato

*Se io **non** sarò arrestato di nuovo, che probabilità ho di essere segnalato lo stesso?*

	Non riarrestati	Segnalati per errore	Falsi allarmi
Gruppo A	50	10	**20%**
Gruppo B	80	4	**5%**

Verdetto

Un innocente del gruppo A rischia di essere bollato "pericoloso" **quattro volte più spesso** di un innocente del gruppo B.

Da questo punto di vista, il sistema è iniquo.

Terza domanda: chi sfugge?

La domanda della sicurezza pubblica

Tra chi sarà arrestato di nuovo, quanti il sistema non ha visto?

	Riarrestati	Non segnalati	Casi sfuggiti
Gruppo A	50	10	**20%**
Gruppo B	20	4	**20%**

Verdetto

Qui i due gruppi sono trattati allo stesso modo.

Due domande su tre dicono "equo". Una dice "iniquo". Stesso sistema, stessi dati.

Perché succede: la rete più larga

Seguiamo il ragionamento

1. Nel gruppo A ci sono più persone che saranno arrestate di nuovo: 50 invece di 20.
2. Per "prenderne" la stessa quota (80%), il sistema deve segnalare **molte più persone** nel gruppo A: 50 contro 20.
3. Una rete più larga raccoglie anche più **innocenti**.
4. E nel gruppo A gli innocenti sono **di meno** (50 contro 80): ogni errore pesa di più sul loro totale.

Il nodo

Non è un difetto di questo sistema. È una conseguenza **aritmetica** del fatto che l'evento da prevedere è più frequente in un gruppo che nell'altro.

Proviamo a correggere: stessi falsi allarmi per tutti

Ritariamo il sistema in modo che gli innocenti siano segnalati per errore **nella stessa misura** (10%) in entrambi i gruppi, lasciando invariati i casi sfuggiti.

	Falsi allarmi	**Casi sfuggiti**	**Segnalati**	**L'etichetta ha ragione**
Gruppo A	10% (5 su 50)	20%	45	**89%** (40 su 45)
Gruppo B	10% (8 su 80)	20%	24	**67%** (16 su 24)

Il problema si è solo spostato

Ora gli innocenti sono trattati allo stesso modo. Ma l'etichetta "alto rischio" **significa cose diverse** secondo il gruppo.

Per leggerla correttamente, il giudice dovrebbe sapere a quale gruppo appartiene l'imputato — e tenerne conto. Cioè proprio ciò che si voleva evitare.

Il teorema, in parole

Che cosa hanno dimostrato (Chouldechova, 2017; Kleinberg et al., 2016)

Se l'evento da prevedere ha **frequenze diverse** nei due gruppi, e il sistema **non è perfetto**, non si possono avere contemporaneamente:

1. un'etichetta che vale lo stesso in tutti i gruppi
2. gli stessi falsi allarmi in tutti i gruppi
3. gli stessi casi sfuggiti in tutti i gruppi

Bisogna rinunciare ad almeno una delle tre.

Che cosa non dice il teorema

- Non dice che il sistema sia mal costruito: vale per *qualunque* sistema, anche il migliore
- Non dice quale delle tre sacrificare: **questa è una scelta, non un calcolo**

Ma da dove vengono le frequenze diverse?

Il dettaglio che cambia tutto

COMPAS non poteva sapere chi avrebbe commesso un nuovo reato. Sapeva solo chi sarebbe stato **arrestato di nuovo**.

E un arresto dipende anche da dove si guarda

- Se un gruppo vive in quartieri più pattugliati, i suoi reati vengono scoperti di più
- La frequenza "vera" dei reati può essere più simile di quanto dicano i dati
- Il teorema parte dai dati come sono: **se i dati sono distorti, lo è anche il punto di partenza**

La statistica ci dice che bisogna scegliere.
Non ci dice se i numeri su cui scegliamo sono giusti.

Quale equità? Una domanda di valori

Se scelgo di garantire...	Proteggo...	Chi lo chiede
un'etichetta che vale lo stesso per tutti	la coerenza di chi decide sulla base del punteggio	il giudice, l'amministrazione
gli stessi falsi allarmi	gli innocenti di ogni gruppo dal sospetto ingiustificato	l'imputato, il cittadino
gli stessi casi sfuggiti	la collettività, in modo uniforme tra i gruppi	la sicurezza pubblica

Domanda per l'aula: se foste voi a dover scegliere, a quale delle tre rinuncereste? E chi dovrebbe poterlo sapere?

Che cosa portarsi in ufficio

Davanti a un sistema che assegna punteggi di rischio

- **Quale definizione di equità** è stata adottata? Chi l'ha scelta?
- Gli errori sono stati **misurati gruppo per gruppo**, e non solo in media?
- L'evento che il sistema prevede è davvero quello che ci interessa, o un suo **sostituto** (come l'arresto al posto del reato)?
- La scelta è **documentata**, e conoscibile da chi subisce la decisione?

In una frase

"Il sistema è equo" non è mai una risposta completa.
La risposta completa è: **equo rispetto a che cosa, e deciso da chi**.

Per i curiosi: perché i conti non possono tornare

Il legame tra le tre misure (facoltativo)

In ogni gruppo, i falsi allarmi dipendono da tre cose:

- quanto è frequente l'evento nel gruppo
- quanto vale l'etichetta "alto rischio"
- quanti casi sfuggono

Se le ultime due sono uguali nei due gruppi ma la prima no, i falsi allarmi **devono** essere diversi.

La formula, solo come curiosità

$$\text{falsi allarmi} = \frac{p}{1-p} \cdot \frac{1 - \text{valore dell'etichetta}}{\text{valore dell'etichetta}} \cdot (1 - \text{casi sfuggiti})$$

dove p è la frequenza dell'evento nel gruppo.

Gruppo A: $\frac{0{,}5}{0{,}5} \cdot \frac{0{,}2}{0{,}8} \cdot 0{,}8 = 20\%$ Gruppo B: $\frac{0{,}2}{0{,}8} \cdot \frac{0{,}2}{0{,}8} \cdot 0{,}8 = 5\%$