

Intelligenza Artificiale per la Pubblica Amministrazione

Incontro 2 — Parte 2: Bias e responsabilità algoritmica

Giovanni Della Lunga
`giovanni.dellalunga@unibo.it`

Università di Bologna

2025 / 2026

Indice della Parte 2

Due modi molto diversi di incontrare l'IA

Stamattina: l'IA come *strumento*

- ▶ **Voi** decidete di usarla
- ▶ **Voi** formulate la richiesta
- ▶ **Voi** valutate l'output
- ▶ **Voi** potete scartarlo
- ▶ Se sbaglia, ve ne accorgete

Il controllo è vostro.

Adesso: l'IA come *decisore*

- ▶ Il **sistema** classifica un cittadino
- ▶ Il **sistema** assegna un punteggio
- ▶ Il **sistema** raccomanda un esito
- ▶ Voi lo ricevete già fatto
- ▶ Se sbaglia, forse **nessuno se ne accorge**

Il controllo è... di chi?

La seconda situazione è quella che riguarderà sempre di più la pubblica amministrazione.

Perché questa parte è la più importante

Un ragionamento semplice

- ▶ Un errore di ChatGPT che scrive male un avviso: **si corregge**.
- ▶ Un errore di un sistema che classifica come “ad alto rischio” un cittadino innocente: **può non essere mai scoperto**.

L'asimmetria che dovrebbe inquietarci

Chi subisce una decisione algoritmica sfavorevole:

- ▶ Spesso **non sa** che c'è stato un algoritmo
- ▶ Se lo sa, **non sa come funziona**
- ▶ Se lo sapesse, **non potrebbe verificarlo**
- ▶ E chi ha firmato il provvedimento, **spesso non lo sa neanche lui**

Il bias: una definizione operativa

Che cos'è un bias algoritmico

Un **errore sistematico** — non casuale — per cui un sistema produce risultati che svantaggiano in modo consistente un determinato gruppo di persone.

Il punto cruciale, spesso frainteso

Il bias **non è un difetto di programmazione**.

Nessuno ha scritto una riga di codice che dice “*penalizza il gruppo X*”. Il sistema funziona **esattamente come progettato**: ha imparato dai dati che gli sono stati dati.

Il problema è nei dati. E i dati siamo noi.

Un algoritmo addestrato sulla storia riproduce la storia — comprese le sue ingiustizie.

Il bias di conferma: il nostro contributo

Definizione

Il **bias di conferma** è il pregiudizio cognitivo per cui le persone tendono a interpretare le nuove informazioni secondo le proprie convinzioni preesistenti.

Implicazioni per l'IA:

- ▶ I sistemi di IA possono **rafforzare** i bias già presenti nei dati
- ▶ Il rischio è che le decisioni automatizzate **riflettano pregiudizi umani**
- ▶ Particolarmente critico in contesti ad alto impatto sociale:
 - Giustizia penale
 - Assistenza sanitaria
 - Finanza, alloggi, occupazione
 - **Immigrazione e ordine pubblico**

È necessaria una **consapevolezza critica** per contrastare questi effetti sistemici.

Le quattro strade per cui il bias entra in un sistema

1. Bias nei dati storici

I dati registrano il *passato*. Se il passato era discriminatorio, i dati lo sono.

Es.: dati sugli arresti riflettono dove la polizia ha pattugliato, non dove sono avvenuti i reati.

2. Bias di campionamento

Alcuni gruppi sono **sotto-rappresentati** nei dati.

Es.: i sistemi di riconoscimento facciale addestrati prevalentemente su volti maschili e chiari.

3. Bias nell'etichettatura

Chi ha etichettato i dati aveva i propri pregiudizi.

Es.: che cosa conta come “comportamento sospetto”? Lo decide un essere umano.

4. Bias nella scelta delle variabili

Le *proxy*: variabili apparentemente neutre che nascondono caratteristiche protette.

Es.: il CAP di residenza può essere una proxy quasi perfetta dell'origine etnica.

Le variabili *proxy*: il bias che si nasconde

Il trucco che non funziona

“Basta togliere l’etnia dalle variabili, e il sistema non può discriminare.”


Falso. Il sistema ricostruisce l’informazione da altre variabili.

Variabili che sono proxy quasi perfette

- ▶ **CAP / quartiere di residenza** → origine etnica, reddito
- ▶ **Nome e cognome** → origine nazionale
- ▶ **Scuola frequentata** → classe sociale
- ▶ **Tipo di contratto di lavoro** → età, genere
- ▶ **Storia dei contatti con la PA** → fragilità sociale

**Rimuovere la variabile sensibile non rimuove la discriminazione.
La rende solo più difficile da individuare.**

Il *feedback loop*: come il bias si autoalimenta



La spirale
si stringe
a ogni giro

Il paradosso

Il sistema **sembra funzionare sempre meglio**: le sue previsioni si avverano.
Ma si avverano **perché il sistema le ha causate**, non perché fossero corrette.

COMPAS: l'algoritmo che prevede la recidiva

Che cos'è

COMPAS (*Correctional Offender Management Profiling for Alternative Sanctions*) è un sistema usato in numerosi tribunali statunitensi per stimare la probabilità che un imputato commetta nuovi reati.

Come funziona:

- ▶ Un questionario di oltre 100 domande sull'imputato
- ▶ Produce un punteggio di rischio da **1 a 10**
- ▶ Il punteggio è usato dai giudici per decisioni su **cauzione**, **libertà vigilata**, talvolta **entità della pena**
- ▶ È un sistema **proprietario**: l'algoritmo è segreto

Milioni di persone valutate. Nessuno, fuori dall'azienda, sa esattamente come.

COMPAS: l'inchiesta

2016: ProPublica analizza i dati

Un gruppo di giornalisti investigativi esamina i punteggi COMPAS di oltre settemila imputati in Florida, e li confronta con ciò che è *effettivamente* accaduto nei due anni successivi.

Che cosa emerge

- ▶ Gli imputati **afroamericani** avevano una probabilità molto più alta di essere classificati erroneamente come **ad alto rischio** pur non commettendo nuovi reati
- ▶ Gli imputati **bianchi** avevano una probabilità molto più alta di essere classificati erroneamente come **a basso rischio** pur commettendo nuovi reati
- ▶ **Gli errori non erano distribuiti a caso. Erano distribuiti secondo l'etnia.**

COMPAS: la difesa dell'azienda

La replica di Northpointe (l'azienda produttrice)

“Il nostro sistema è equo: a parità di punteggio, la probabilità di recidiva è la stessa per tutti i gruppi etnici.”

E qui viene il punto più interessante di tutta la storia

Avevano ragione entrambi.

ProPublica misurava una cosa (*gli errori sono distribuiti in modo diseguale*).

Northpointe ne misurava un'altra (*a parità di punteggio, il rischio è lo stesso*).

Entrambe le affermazioni erano **statisticamente vere**.

Com'è possibile?

Il teorema dell'impossibilità

Un risultato matematico dimostrato

Quando i **tassi di base** sono diversi tra due gruppi (nel caso COMPAS: tassi di arresto storicamente diversi), è **matematicamente impossibile** soddisfare contemporaneamente tutte le definizioni ragionevoli di equità.

Bisogna **scegliere** quale forma di equità garantire.

La conseguenza, che va compresa a fondo

Non esiste un algoritmo “equo” in assoluto.

Ogni sistema incorpora una **scelta di valore** su quale forma di equità privilegiare.

Questa scelta è **politica**, non tecnica. E quasi sempre viene fatta da un ingegnere, in silenzio, senza che nessuno se ne accorga.

COMPAS: che cosa ci insegna

- 1 **Il bias non richiede cattiva fede.** Nessuno voleva discriminare.
- 2 **L'opacità impedisce il controllo.** L'algoritmo era segreto: nemmeno i giudici sapevano come funzionava.
- 3 **L'equità non è un problema tecnico.** È una scelta politica travestita da specifica tecnica.
- 4 **L'apparenza di oggettività è pericolosa.** Un numero da 1 a 10 sembra un fatto. Non lo è.
- 5 **Senza audit indipendenti, nessuno se ne accorge.** Ci sono voluti dei giornalisti.

Un giudice che si discosta dalla raccomandazione dell'algoritmo
deve motivare. Uno che la segue, no.
Indovinate quale comportamento diventa la norma.

La polizia predittiva

L'idea

Usare i dati storici sui reati per **prevedere dove** avverranno i prossimi, e concentrare lì le pattuglie.

PredPol è stato il sistema più diffuso negli Stati Uniti.

Perché sembra un'ottima idea

- ▶ Ottimizza risorse scarse
- ▶ Sembra oggettivo: si basa sui dati, non sull'intuito
- ▶ Promette di prevenire, non solo di reprimere
- ▶ È politicamente vendibile: “*polizia scientifica*”

Ed è esattamente per questo che è pericoloso.

PredPol: il vizio d'origine

Su quali dati si basa il sistema?

Sui dati storici di **arresti e denunce**. Quindi su dati **spesso influenzati da pratiche di polizia già discriminatorie**.

Il meccanismo, passo per passo

- 1 Storicamente la polizia ha pattugliato di più certi quartieri
- 2 In quei quartieri sono stati registrati **più arresti** — non necessariamente più reati
- 3 Il sistema impara: “*qui succedono più cose*”
- 4 Il sistema manda più pattuglie in quei quartieri
- 5 Più pattuglie → **più arresti**
- 6 I nuovi arresti **confermano** la previsione
- 7 Torna al punto 3

Un classico feedback loop, ben documentato sia teoricamente sia empiricamente.

PredPol: le conseguenze

Che cosa accade nella realtà

- ▶ Le aree più pattugliate — tipicamente comunità povere e di minoranza — **generano più dati**, che alimentano previsioni ulteriormente sbilanciate
- ▶ Interi quartieri, già stigmatizzati, rischiano di essere **sorvegliati e criminalizzati ingiustamente**
- ▶ La spirale si autoconferma: più sorveglianza produce più dati, che giustificano più sorveglianza

L'assenza di controllo

- ▶ Molti algoritmi sono **proprietary** (*black box*): né la comunità né le autorità possono verificarne il funzionamento
- ▶ **Senza audit indipendenti**, un programma può continuare a operare per anni malgrado effetti negativi tangibili — come è accaduto con PredPol, attivo a lungo pur in assenza di prove convincenti della sua efficacia

Perché questo riguarda l'Italia

Non è un problema americano

Sistemi analoghi sono stati sperimentati o adottati in Europa, e l'**AI Act** classifica esplicitamente come **ad alto rischio** i sistemi di IA usati in:

- ▶ Attività di contrasto (*law enforcement*)
- ▶ Gestione della migrazione e dei controlli di frontiera
- ▶ Amministrazione della giustizia
- ▶ Accesso a servizi pubblici essenziali

Questi non sono ambiti astratti.
Sono gli ambiti in cui lavorate voi.

Altri casi europei: il sistema SyRI (Paesi Bassi) MODIFICARE

Che cos'era

Un sistema usato dal governo olandese per individuare possibili frodi nel welfare, incrociando dati provenienti da fonti diverse e assegnando punteggi di rischio ai cittadini.

Come è finita

- ▶ Il sistema veniva applicato prevalentemente nei **quartieri più poveri**
- ▶ Il funzionamento era **opaco**: i cittadini non sapevano di essere valutati
- ▶ Nel **2020** un tribunale dell'Aja ne ha dichiarato l'**illegittimità** per violazione dei diritti umani
- ▶ Il caso si è intrecciato con lo scandalo degli assegni familiari, che ha travolto famiglie innocenti e portato alle **dimissioni del governo**

Un governo caduto. Per un algoritmo.

Il problema dell'opacità

Le applicazioni di IA come *black box*

- ▶ Producono risultati **accurati**, ma spesso **non interpretabili**
- ▶ Nemmeno i programmatori riescono a spiegare come si formano le decisioni
- ▶ Criticissimo in contesti ad alto impatto umano: medicina, diritto, amministrazione

Due tipi di opacità, spesso confusi

- ▶ **Opacità commerciale**: l'algoritmo è segreto perché è proprietà industriale. *È un problema di potere.*
- ▶ **Opacità intrinseca**: anche avendo il codice, una rete con miliardi di parametri **non è comprensibile**. *È un problema tecnico.*

Il primo si risolve con la legge. Il secondo, no.

Definizione (Ribeiro et al., 2016)

La capacità di **comprendere e spiegare** il processo decisionale di un modello.

Perché è essenziale:

- ▶ Per evitare errori, discriminazioni, danni sistemici
- ▶ Perché **anche un modello preciso può essere rischioso** se non è comprensibile a chi lo usa
- ▶ Perché senza spiegazione non c'è **contestabilità**
- ▶ Perché senza contestabilità non c'è **tutela**

**La spiegabilità non è solo desiderabile:
è essenziale per un uso etico e responsabile dell'IA.**

Come si ottiene la spiegabilità

Metodi intrinseci

Modelli che sono **interpretabili per costruzione**: alberi decisionali, regressione lineare e logica, modelli lineari generalizzati.

La relazione tra input e output è **chiara e leggibile**. Potete letteralmente seguire il ragionamento.


Metodi *post hoc*

Spiegazioni costruite **dopo**, cercando di ricostruire il comportamento di un modello opaco (LIME, SHAP).

Danno un'idea di quali variabili hanno pesato di più — ma sono **approssimazioni**, non la verità del modello.

**Un modello intrinsecamente spiegabile è una base solida
per un'IA trasparente e responsabile.**

Il compromesso: precisione contro spiegabilità



Il contesto decide

- ▶ In **medicina** o **diritto** → meglio modelli spiegabili, anche a costo di qualche punto di precisione
- ▶ In **meteorologia** o **logistica** → può prevalere la precisione
- ▶ **Nella PA** → la spiegabilità non è un lusso: è un requisito di legittimità

Non esiste una spiegazione “taglia unica”

Utenti diversi hanno bisogni esplicativi diversi

- ▶ Un **ingegnere** vuole sapere quali parametri hanno pesato
- ▶ Un **dirigente** vuole sapere se il sistema è affidabile nel complesso
- ▶ Un **funzionario** vuole sapere se può fidarsi di *questa* specifica raccomandazione
- ▶ Un **cittadino** vuole sapere **perché proprio a lui** è stato negato qualcosa
- ▶ Un **giudice** vuole sapere se la decisione è difendibile

**La spiegabilità va adattata a chi deve capire.
Una spiegazione che nessuno comprende non è una spiegazione.**

Il principio di supervisione umana significativa

Che cosa dice la normativa

Per i sistemi ad alto rischio, l'AI Act richiede che sia garantito un **controllo umano significativo**, con la possibilità concreta di **intervenire, interrompere o annullare** le decisioni automatizzate.

Che cosa NON È supervisione significativa

- × Apporre una firma su un provvedimento già redatto dal sistema
- × Cliccare “conferma” su una schermata
- × Avere *teoricamente* la possibilità di dissentire, ma senza tempo né informazioni per farlo
- × Essere l'unico responsabile in caso di errore, senza avere avuto strumenti reali di controllo

La firma finale non basta. Mai.

Le tre condizioni di una supervisione reale

1. Competenza

Chi supervisiona deve *capire* che cosa il sistema sta facendo. Non deve saperlo programmare, ma deve conoscerne limiti, logica generale e modalità tipiche di errore.

2. Informazione

Chi supervisiona deve avere accesso a *tutti* gli elementi su cui il sistema ha basato la raccomandazione. Un punteggio senza motivazione non è supervisionabile.

3. Autorità e tempo

Chi supervisiona deve poter *davvero* dissentire, senza penalizzazioni, e deve avere il tempo materiale per farlo.

Se manca anche una sola di queste tre

Non c'è supervisione umana.

C'è solo un umano che si prende la responsabilità della macchina.

L'automation bias

Definizione

La tendenza sistematica a **fidarsi eccessivamente** di un sistema automatizzato, accettandone i suggerimenti anche quando elementi contrari sarebbero disponibili.

Si manifesta in due forme:

- ▶ **Errori di commissione:** seguo il sistema anche quando ho informazioni che lo contraddicono
- ▶ **Errori di omissione:** non noto un problema perché il sistema non me lo ha segnalato

Il paradosso della delega

**Più il sistema è sofisticato e affidabile,
più diventa difficile esercitare su di esso un controllo critico efficace.**

Se sbaglia una volta su mille, dopo novecento volte che ha ragione... chi ha ancora la lucidità di controllare?

Perché ci fidiamo troppo: i meccanismi

1. L'aura di oggettività del numero

Un punteggio “7,4 su 10” sembra un *fatto*. Un parere umano sembra un’*opinione*. Ma il 7,4 è anch’esso un’opinione, cristallizzata in cifra.

2. La riduzione dello sforzo cognitivo

Pensare costa fatica. Accettare no. Il cervello sceglie la via meno cara.

3. La diffusione della responsabilità

“*L’ha detto il sistema*” è psicologicamente rassicurante — anche se giuridicamente non vi protegge affatto.

4. L’asimmetria degli incentivi

Seguire il sistema e sbagliare: *ho seguito la procedura*.

Discostarsi e sbagliare: *me ne assumo tutta la colpa*.

Il sistema di incentivi premia la passività.

Come difendersi dall'*automation bias*

Strategie individuali

- ▶ **Formulare la propria ipotesi prima** di guardare la raccomandazione del sistema
- ▶ Chiedersi sempre: *“su quali dati si sta basando?”*
- ▶ Prestare attenzione particolare ai casi in cui il sistema **conferma** ciò che già pensavate (lì il controllo si abbassa di più)
- ▶ Trattare il divergere dal sistema come **normale**, non come eccezionale

Strategie organizzative

- ▶ **Non chiedere di motivare solo il dissenso**: chiedere di motivare *anche l'adesione*
- ▶ Prevedere **controlli a campione** sui casi in cui si è seguito il sistema
- ▶ **Monitorare** il tasso di adesione: se è vicino al 100%, la supervisione è finzione

Esercizio — Lo scenario

Il contesto (fittizio)

Il vostro ente ha adottato in via sperimentale un sistema di supporto decisionale che analizza le istanze in arrivo e assegna a ciascuna un **punteggio di priorità** e un **indicatore di rischio** (verde / giallo / rosso), per orientare l'ordine di lavorazione e il livello di approfondimento istruttorio.

Il caso

Vi arriva una pratica con:

- ▶ **Punteggio di rischio: 8,2 / 10** — indicatore **ROSSO**
- ▶ Raccomandazione del sistema: *“approfondimento istruttorio rafforzato”*
- ▶ Nessuna motivazione fornita
- ▶ La documentazione presentata dal richiedente vi sembra, a prima vista, **del tutto regolare**

Esercizio — Lavoro in piccoli gruppi (20 minuti)

Discutete e mettete per iscritto

- 1 **Che cosa fate?** Seguite la raccomandazione, la ignorate, o fate altro?
- 2 **Quali informazioni vi mancano** per decidere in modo fondato?
- 3 **Che cosa chiedereste al sistema**, se poteste interrogarlo?
- 4 **A chi vi rivolgereste** dentro l'ente?
- 5 **Se decidete di discostarvi**, come motivate il provvedimento?
- 6 **Se decidete di seguirlo**, come lo motivate?

Nota: la domanda 6 è quella che quasi nessuno si pone. Ed è la più insidiosa.

Esercizio — Le domande che dovrebbero emergere

Sul sistema

- ▶ Su quali **variabili** si basa il punteggio?
- ▶ Su quali **dati storici** è stato addestrato?
- ▶ Qual è il suo **tasso di errore**? E come si distribuisce?
- ▶ Chi lo ha **validato**? È stato sottoposto ad audit?
- ▶ Il punteggio è stato **tarato** su una popolazione simile alla nostra?

Sul procedimento

- ▶ Il richiedente **sa** di essere stato profilato?
- ▶ Il punteggio finirà nella **motivazione** del provvedimento?
- ▶ In caso di ricorso, **che cosa esibiremo**?
- ▶ Se il sistema sbaglia sistematicamente su un certo gruppo, **chi se ne accorgerebbe**?

Esercizio — Il debriefing

Confrontiamo le scelte dei gruppi

- ▶ Quanti hanno **seguito** la raccomandazione?
- ▶ Quanti se ne sono **discostati**?
- ▶ Quanti hanno pensato di **chiedere informazioni** prima di decidere?
- ▶ Quanti si sono chiesti se il richiedente **sapesse** di essere valutato da un algoritmo?

L'osservazione scomoda

Nella maggior parte delle simulazioni di questo tipo, la **maggioranza segue il sistema**.

Non per pigrizia. Per una ragione molto più razionale: **discostarsi costa**, e il sistema di incentivi non premia chi lo fa.

Ecco perché il problema non è mai solo individuale. È **organizzativo**.

I punti fermi di questa seconda parte

- 1 Il **bias** non nasce dalla cattiva fede: nasce dai **dati**, che riflettono la nostra storia.
- 2 Rimuovere la variabile sensibile **non elimina** la discriminazione: la nasconde.
- 3 I **feedback loop** rendono il bias autoconfermante: il sistema sembra sempre più accurato mentre diventa sempre più ingiusto.
- 4 Non esiste un algoritmo **equo in assoluto**: l'equità è una scelta di valore, non un parametro tecnico.
- 5 L'**opacità** impedisce il controllo, e senza controllo non c'è tutela.
- 6 La **supervisione umana** richiede competenza, informazione, autorità e tempo. Senza, è finzione.
- 7 L'**automation bias** è strutturale: dipende dagli incentivi, non dalla buona volontà.

Un sistema algoritmico non solleva mai
l'amministrazione dalla responsabilità.

La sposta soltanto — rendendola
più difficile da vedere e da esercitare.

*Ed è esattamente per questo che serve
un funzionario che sappia guardare dentro la scatola.*

Cosa faremo nel terzo incontro

Incontro 3 — Governare l'IA

Prima parte: il quadro normativo

- ▶ L'AI Act: struttura e approccio basato sul rischio
- ▶ I sistemi ad alto rischio e gli obblighi per chi li usa
- ▶ Calendario di attuazione e sanzioni
- ▶ GDPR e trattamento dei dati personali

Seconda parte: etica e pratica

- ▶ I principi etici dell'IA nella PA
- ▶ Come valutare un sistema prima di adottarlo
- ▶ Come documentare l'uso dell'IA in un procedimento
- ▶ **Tre esercitazioni pratiche** con ChatGPT, Claude e Copilot
- ▶ Prospettive e chiusura del corso

Grazie

Domande e discussione

Giovanni Della Lunga

`giovanni.dellalunga@unibo.it`

Università di Bologna

Materiale del corso:

`https://github.com/polyhedron-gdl`